

Segmentación de Clientes de e-commerce

Autor: Alberth Pinco Bravo

1. Introducción

En el comercio electrónico, comprender el comportamiento de los usuarios es fundamental para optimizar las estrategias de marketing y mejorar la retención de clientes. El objetivo de este proyecto es segmentar a los visitantes de un sitio web en grupos con características homogéneas, utilizando un conjunto de datos de Google Analytics que registra el origen de las visitas, los tipos de dispositivos y las métricas de interacción en la sesión. A través de este análisis, se busca transformar los datos brutos en perfiles de clientes accionables que faciliten la toma de decisiones estratégicas en la empresa.

2. Descripción EDA y preprocesamientos realizados

Para comenzar con el proyecto, se realizó una auditoría inicial sobre cada columna del dataset con el fin de detectar posibles problemas en la calidad de los datos. En cuanto a esto, se corrigieron las inconsistencias encontradas en las columnas `channelGrouping`, `device_browser`, `device_isMobile` y `trafficSource_medium`, estandarizando sus formatos según correspondió y eliminando el único valor nulo encontrado. Asimismo, se hicieron reagrupaciones en las columnas `device_browser`, `device_operatingSystem`, `trafficSource_medium`, agrupando las etiquetas de baja frecuencia para disminuir el ruido al momento de hacer la segmentación.

Posteriormente, se graficaron las distribuciones de las diferentes columnas y se calcularon algunos estadísticos para identificar tendencias y entender mejor el comportamiento de los usuarios. En cuanto a esto, se observaron varios puntos clave:

1. La mayor parte del tráfico proviene de **Referidos** (44 %) y **Búsquedas Orgánicas** (32 %), seguido de Tráfico Directo (18 %), indicando que el sitio cuenta con un buen posicionamiento y reconocimiento de marca, dependiendo en menor medida de los canales de pauta paga, los cuales representan en conjunto el 6 % del tráfico total (véase el primer gráfico de la [Figura 1](#)).
2. Más de la mitad de los usuarios (56 %) son usuarios Macintosh, solo un 20 % son usuarios de Windows, y el 25 % restante están distribuidos en los diferentes sistemas operativos tales como Linux, iOS, Android, Windows Phone y Chrome OS (véase el segundo gráfico de la [Figura 1](#)).




Figura 1. Distribución de las visitas al sitio web según el medio de tráfico y el sistema operativo.

3. El 90 % del tráfico ocurre desde un **computador de escritorio**, el 8 % desde un teléfono móvil y solo un 2 % desde tablets, indicando desde esta etapa inicial que lo más conveniente es optimizar el sitio web para pantallas grandes en formato horizontal (véase el primer gráfico de la [Figura 2](#)).
4. Casi el 90 % del tráfico ocurre desde el navegador **Chrome**, solo un 7 % desde Safari y el resto desde otros navegadores (véase el segundo gráfico de la [Figura 2](#)).
5. El volumen de visitas se concentra fuertemente en la tarde, iniciando un incremento marcado desde las 12:00 y alcanzando un **pico entre las 17:00 y las 18:00** (véase [Figura 3](#)). Este patrón refleja una alta actividad durante el cierre de la jornada laboral, mientras que el periodo de menor actividad ocurre entre las 6:00 y las 11:00 de la mañana, identificándose como un horario ineficiente para pautas publicitarias.
6. La mayor parte del tráfico se concentra de **lunes a viernes**, registrando una proporción baja de accesos durante los fines de semana.

Ahora bien, en cuanto a las distribuciones de las variables `totals_hits` y `totals_pageviews`, se observó una fuerte presencia de valores atípicos, registrándose máximos de hasta 500 interacciones y 466 páginas vistas. Por esta razón, dado que apenas un 25 % de las visitas al sitio web supera los 28 hits y solo el 1 % supera los 100, se tomó la decisión de mitigar este sesgo acotando ese 1 % de los datos atípicos a un límite máximo de 100 hits, tal como se observa en el histograma de la [Figura 4](#). En el boxplot de esta misma figura se puede notar que el 50 % central de los datos interactúa en un rango de entre 9 y 28 veces. De manera similar, para la variable `totals_pageviews`, dado que solo




Figura 2. Distribución de las visitas al sitio web según el dispositivo y el navegador web.




Figura 3. Distribución de las visitas al sitio web según la hora del día.

el 1% de la muestra superaba las 71 páginas vistas, se fijó este valor como límite superior para eliminar el sesgo y no afectar posteriormente la segmentación.

Finalmente, con el objetivo de preparar los datos para la segmentación, se hizo una codificación One-Hot sobre las variables categóricas y se implementó una transformación logarítmica en las variables `totals_hits` y `totals_pageviews` para mitigar aún más el sesgo. Por último, se normalizaron las variables numéricas continuas mediante un escalado MinMax en un rango de 0 a 1.




Figura 4. Distribución de interacciones tras aplicar un acotado (clipping) al percentil 99.

3. Metodología de segmentación

Para la segmentación de los clientes se seleccionó el algoritmo **K-Means** debido a su eficiencia computacional y escalabilidad. Con el objetivo de determinar el número óptimo de clusters, se realizó un gráfico de codo y también algunos gráficos de silueta para diferentes valores de k . Por un lado, al evaluar la evolución de la inercia en el método del codo, se observó un ligero cambio de pendiente en $k = 5$ (véase el primer gráfico de la [Figura 5](#)), sugiriendo junto con los coeficientes de silueta, que una estructura de cinco segmentos es la más robusta matemáticamente y la que ofrece la mejor interpretabilidad.

4. Resultados, análisis y recomendaciones

Para visualizar la agrupación resultante, se aplicó una reducción de dimensionalidad mediante t-SNE, proyectando los clusters en dos dimensiones (véase el segundo gráfico de la [Figura 5](#)). Esto nos muestra una clara separación estructural entre los núcleos de cada segmento. Adicionalmente, las pequeñas dispersiones o sub-islas observadas son consistentes con la naturaleza multimodal de las variables categóricas tales como los sistemas operativos, el medio de tráfico y los navegadores web.

Las características principales de cada segmento son:

- **Cluster 0:** Usuarios de Windows que llegan al sitio web en mayor medida por búsquedas orgánicas (66 %) y referidos (25 %). Acceden principalmente desde Chrome u otros navegadores (nunca desde Safari) y en un 99 % lo hacen desde un computador de escritorio.




Figura 5. Selección del número óptimo de clusters mediante el método del codo (gráfico izquierdo) y una proyección en el plano de 5 clusters mediante t-SNE (gráfico derecho).

Estrategia recomendada: Dado que el 66 % de estos usuarios llega mediante búsquedas en motores de navegación, la estrategia principal debe enfocarse en optimizar el posicionamiento orgánico (SEO) del sitio web con palabras clave relevantes. Asimismo, al operar casi en su totalidad desde computadores de escritorio, es fundamental garantizar la velocidad de carga y la correcta visualización en el navegador Chrome.

- **Cluster 1 (Los referidos):** Usuarios de Macintosh que llegan únicamente por referidos, utilizando el navegador Chrome y mediante un computador de escritorio. Es el grupo más compacto como se puede observar en la [Figura 5](#) (cluster naranja).

Estrategia recomendada: Al depender exclusivamente de enlaces externos, la prioridad es identificar los dominios exactos que redirigen este tráfico para fortalecer alianzas estratégicas con esos sitios web, blogs o foros de la misma categoría.

- **Cluster 2:** Usuarios de sistemas operativos diferentes a Windows y Macintosh (tales como Linux, Chrome OS, iOS, entre otros). Llegan en buena parte por referidos (41 %) y búsquedas orgánicas (38 %), caracterizándose por ser los únicos que acceden desde dispositivos móviles y tablets, además de computadores.

Estrategia recomendada: De manera similar al Cluster 1, es clave identificar las fuentes de referidos para consolidar la presencia del sitio en esos entornos digitales. Sin embargo, también es importante garantizar un diseño responsivo y una óptima adaptabilidad móvil de la interfaz web, asegurando que la experiencia de navegación fluya sin fricciones en pantallas verticales y dispositivos táctiles.

- **Cluster 3 (Los leales):** Usuarios de diferentes sistemas operativos que llegan al sitio web únicamente por vía directa y exclusivamente desde un computador de escritorio.

Estrategia recomendada: Dado que estos usuarios acceden de forma 100 % directa, el enfoque debe centrarse en la retención de estos clientes. Por lo tanto, se recomienda implementar programas de lealtad como acumulación de puntos o membresías, y promociones exclusivas para incentivar la recompra.

- **Cluster 4:** Usuarios de Macintosh que también acceden únicamente desde computador de escritorio, diferenciándose del cluster 1 en que no llegan por referidos sino por búsquedas orgánicas (83 %) y publicidad (17 %). De todos los clusters, son los que mejor responden a las diferentes estrategias de publicidad.

Estrategia recomendada: Al ser el grupo mas receptivo a la publicidad, se debe concentrar aquí gran parte de los esfuerzos de pauta digital de pago. La acción clave es aprovechar las opciones avanzadas de configuración en las plataformas de anuncios para segmentar exclusivamente por sistema operativo (Macintosh) y por dispositivo (Escritorio), minimizando así el gasto ineficiente en dispositivos móviles o aplicaciones.

Como conclusión macro, el análisis exploratorio inicial (EDA) evidenció que el usuario promedio accede al sitio web a través de computadores de escritorio utilizando el navegador Chrome, concentrando su actividad de lunes a viernes durante la tarde, con un pico crítico entre las 17:00 y las 18:00 horas. Por lo tanto, como recomendación general, se sugiere programar los mantenimientos técnicos o actualizaciones de catálogo en horarios de tráfico bajo (entre las 6:00 y las 11:00 o en fines de semana). Esto garantizará la total disponibilidad del servidor y una velocidad de carga óptima en el entorno de escritorio durante las horas de mayor afluencia.